

YOLOv8을 활용한 노인 낙상사고 감지 모니터링 시스템 개발

Development of a Fall Detection Monitoring System for the Elderly using YOLOv8

김 동 욱¹ 강 신 후^{1*}
Doung Uk Kim Shinhoo Kang

요 약

전 세계적인 고령 인구 증가와 함께 노인 낙상 사고는 심각한 사회·경제적 문제로 대두되고 있다. 특히 대한민국의 경우 고령 인구 비중이 증가함에 따라, 낙상 사고 발생 시 신속한 구조와 대응이 필수적이다. 기존 연구들은 웨어러블 기기, IoT 센서, 고가의 카메라 장비 등 다양한 접근 방식을 제시하였으나, 높은 설치 비용과 관리 부담, 사용자의 불편 등으로 인해 실효성에 제약이 있었다. 본 연구에서는 이러한 한계를 극복하고자, 기존에 설치된 CCTV 영상을 활용하여 별도의 추가 센서 없이 노인 낙상 사고를 실시간으로 감지하는 시스템을 제안한다. 제안 시스템은 YOLOv8 기반의 딥러닝 모델을 활용하여 사람 객체는 YOLOv8m으로, 가구 객체는 YOLOv8x로 각각 검출·추적하고, 이들 간의 공간적 관계 및 움직임 패턴을 분석하여 위험 상황을 판단한다. 또한 낙상으로 추정되는 상황이 발생할 경우, SMS 알림을 전송하여 신속한 응급 대응이 가능하도록 설계하였다. 다섯 가지 시나리오 기반의 실험 결과, 제안 시스템은 정적인 환경에서 높은 검출 정확도와 실시간 응답성을 보였다. 이러한 결과는 사람 객체와 주변 가구 간의 공간적 관계 분석이 낙상 위험 탐지에 효과적으로 활용될 수 있음을 의미한다. 향후 연구에서는 파인튜닝, 알고리즘 개선을 통해 탐지 성능을 향상시키고, 실제 사용자 환경에서 실효성을 검증할 계획이다.

☞ 주제어 : 노인 낙상 감지, CCTV 영상 분석, 객체 검출 및 추적, YOLOv8

ABSTRACT

With the global increase in the elderly population, falls among seniors have become a significant socio-economic issue. In South Korea, where the elderly population is rapidly growing, prompt rescue and response in the event of a fall are crucial. Previous studies have explored various approaches, such as wearable devices, IoT sensors, and expensive camera equipment. However, these methods have limitations including the need for additional device wear, high installation costs, and maintenance burdens. In this study, we propose a system that overcomes these limitations by utilizing existing CCTV footage to detect elderly falls in real-time without the need for extra sensors. The proposed system employs a YOLOv8-based deep learning model, using the YOLOv8m and YOLOv8x models to detect and track both human objects and safety furniture(e.g., chairs, sofas, beds). By analyzing the spatial relationships and movement patterns between these objects, the system is able to identify fall events. Moreover, when a fall is detected, the system is designed to send an SMS alert to enable a rapid emergency response. Experimental results under five scenarios show that the proposed system achieves high detection accuracy and real-time responsiveness in static environments. These results indicate that analyzing the spatial relationship between safety furniture and human objects can be effectively utilized for fall risk detection. In future research, we plan to fine-tune a pre-trained model using fall images, integrate it with a time-series model to further enhance fall detection performance, and validate its effectiveness through evaluations in real-world user environments.

☞ keyword : Elderly Fall Detection, CCTV Video Analysis, Object Detection and Tracking, YOLOv8

1. 서 론

¹ Dept. of Computer Software, Korea University, Sejong 30019, Korea.

* Corresponding author (shinkang@korea.ac.kr)

[Received 27 February 2025, Reviewed 30 April 2025(R2 09 August 2025), Accepted 01 September 2025]

의료 기술의 발전과 출산율의 감소로 인해 전 세계적으로 고령 인구가 빠르게 증가하고 있다[1]. 특히 대한민국은 출산율 감소와 인구 고령화의 가속화로 65세 이상 고령 인구가 전체 인구의 19.2%에 달하며, 이 중 혼자 사

는 노인 가구의 비율도 꾸준히 증가하고 있다[2]. 나이가 들면서 신체 기능이 저하되면 장애물을 인식하는 속도가 느려지고, 균형감각이 약해져서 낙상 사고의 위험이 커진다. 더욱이, 사회적 관계망이 축소됨에 따라 고령자들의 사회적 고립이 발생할 수 있기 때문에, 낙상 사고 발생 시 구조 및 회복이 지연될 수 있다[3]. 미국 소비자제품안전위원회[4]의 보고서에 따르면, 노인 낙상 사고는 주로 집 내부(침실, 욕실, 계단 등)에서 발생하며, 넘어짐으로 인해 많은 노인이 치료를 받거나 장기간 활동이 제한되는 것으로 나타났다[3]. 이처럼 낙상 사고는 고령자의 건강과 생명에 치명적인 영향을 미칠 뿐만 아니라, 가족과 사회의 돌봄 부담을 가중시키는 요인이 된다. 따라서 이는 개인의 건강 문제를 넘어서 사회·경제적으로도 중요한 문제로 대두되고 있다[4].

이러한 중요성으로 인해 노인 낙상 사고 감지에 대한 다양한 연구가 지속적으로 이루어져 왔다. 전통적인 방법으로는 센서가 장착된 웨어러블 기기를 활용하는 방법[5]과 낙상으로 인해 발생하는 음성과 진동을 분석하는 방법[6]이 제안되었다. 그러나 이러한 방식은 모두 사용자가 별도의 장치를 착용해야 한다는 점에서, 추가적인 비용과 관리 부담뿐만 아니라 사용자의 불편함도 따른다는 한계가 존재한다. 일부 연구에서는 라이더[7]나 열화상 카메라[8] 등 고가의 장비를 활용한 카메라 기반 접근법이 시도되었으나, 초기 설치 비용 및 유지 보수 비용이 많이 들며, 복잡한 실내 환경과 장애물을 효과적으로 처리하기가 쉽지 않다. 따라서, 최근에는 저비용으로 쉽게 설치할 수 있는 CCTV 기반 낙상 사고 감지 시스템에 관한 연구가 주목을 받고 있다[9]. CCTV 카메라는 라이더나 열화상 카메라보다 훨씬 저렴하여 추가 설치가 쉬울 뿐만 아니라, 병원이나 요양원과 같은 공간에서는 이미 설치되어 있는 경우가 많아 활용성이 높다. 또한, 웨어러블 장비와 달리 별도의 충전이 필요하지 않아 관리가 편하며, 비접촉 방식이기 때문에 사용자에게 거부감을 주지 않는 장점이 있다.

본 연구에서는 이러한 연구 경향에 맞추어, 노인 낙상 사고의 조기 감지와 신속 대응을 위한 영상 기반 딥러닝 시스템을 제안한다. 영상 기반 낙상 감지 연구는 크게 단일 카메라 방식과 다중 카메라 방식으로 나눌 수 있다. 단일 카메라 방식은 계산 부담이 적어 실시간 처리가 쉽지만, 2차원 영상 기반 분석이므로 깊이 정보가 부족해 자세 인식의 한계가 있을 수 있다. 반면, 다중 카메라 접근법은 다양한 시점에서 영상을 확보할 수 있어 사각지대를 줄이고, 정교한 3차원 분석을 통해 깊이 정보를 활

용할 수 있는 장점이 있다. 하지만, 고용량 데이터를 실시간으로 처리하기 위해서는 높은 하드웨어 비용과 함께, 영상을 효과적으로 처리할 수 있는 복잡한 기술이 필요하다. 이에 본 연구에서는 요양원이나 가정에서 실용적으로 활용할 수 있도록 단일 카메라 기반 낙상 감지 시스템을 개발하였다. 제안하는 시스템은 실시간 객체 탐지 모델로 널리 알려진 YOLOv8[13]을 활용하여, 영상 내의 사람과 안전 가구*를 객체 단위로 검출·추적한다. 노인이 안전 가구를 활용하여 낙상의 위험을 줄일 수 있다는 가정 아래, 본 연구는 안전 가구와 사람 간의 상대적 위치를 활용하여 낙상 상황을 판단하였다. 이를 통해 단일 카메라 기반 낙상 감지 시스템이 갖는 자세 인식의 한계를 보완할 수 있다. 또한, 낙상이 의심되는 상황이 발생하면 SMS 알림을 전송하여 신속한 구조와 응급 대응이 가능하도록 설계하였다. 개발된 시스템은 동적 상황, 정적 상황, 안전 가구와의 공간적 관계를 고려한 다섯 가지 시나리오에서 평가를 진행하였으며, 높은 정확도로 낙상을 감지할 수 있음을 확인하였다.

본 논문의 구성은 다음과 같다. 2장에서는 CNN과 YOLO를 활용한 기존 낙상 감지 연구를 살펴보고, 3장에서는 제안하는 낙상 감지 시스템의 구조와 동작 방식을 설명한다. 4장에서는 시나리오에 따른 실험 결과 및 분석을 제시하며, 마지막으로 5장에서 연구의 결론과 향후 과제에 대해 논의한다.

2. 관련 연구

CCTV 카메라에서 촬영된 컬러 영상을 활용하여 낙상을 감지하는 것은 일반적으로 매우 많은 정보를 처리해야 한다는 것을 의미한다. 이 때문에 실시간으로 영상을 처리하는 것은 쉬운 문제가 아니다. 하지만 딥러닝 기술의 비약적인 발전으로 이것이 가능해졌다.

Wang et al.(2016)과 Yu et al.(2017)은 이미지에서 사람의 실루엣을 추출하고, Convolution Neural Network(CNN)를 활용하여 걸음, 넘어짐, 누움과 같은 자세를 분류하여 낙상 여부를 판단했다[11]. 그러나 이러한 방법은 이미지에서 흑백 형태로 사람의 형상을 추출해야 하므로 배경과 사람을 분리하는 과정에서 오차가 발생할 가능성이 크다[12]. 이에 따라 실루엣 이미지 대신 RGB 색상 이미지에 직접 CNN을 적용하여 특징을 추출하고 낙상을 탐

* 여기서 ‘안전 가구’는 특별히 제작된 가구가 아니라, 낙상 시 충격을 완화하여 부상을 예방할 수 있는 침대, 소파, 의자와 같은 일반 가정용 가구를 의미한다.

지하는 연구가 제안되었다[13]. Tian et al.(2022) 또한 RGB 컬러 이미지에서 사람 객체를 탐지한 후, 관절 위치를 분석하여 자세를 추출하고, CNN을 활용해 시공간 지도를 구성하여 자세를 예측하는 방법을 제안하였다[14]. Lu et al.(2018)은 더 나아가 3차원 CNN을 활용해 시공간 RGB 이미지로부터 낙상 움직임을 추출하는 방법을 제안했다[15].

CNN 기반 방법은 높은 정확도를 제공하지만, 연산량이 많아 비용이 증가하는 단점이 있다. 이에 따라 최근에는 가볍고 빠른 객체 탐지 모델인 YOLO가 낙상 감지 연구에서 활발히 활용되는 추세이다[16, 17, 18]. Gomes et al.(2022)는 YOLOv3를 이용하여 사람 객체를 찾아내고, 3차원 CNN과 결합하여 시간 변화에 따른 움직임을 분석하여 낙상 여부를 판단했다[16]. Agrawal and Agrawal(2023)은 YOLOv4를 이용해 사람 객체를 탐지한 후, 시퀀스 데이터 처리를 위해 장·단기 기억 네트워크(Long Short-Term Memory, LSTM)를 적용하였다[17]. Krishnan et al.(2024)는 YOLOv8 단독으로 낙상 감지를 수행하였으며, YOLOv3 및 YOLOv5와 비교하여 정확도가 10% 이상 향상됨을 보였다[18].

2.1 YOLOv8 구조

YOLO는 2016년 처음 발표된 이후, 성능 개선과 실용성을 높이기 위해 지속적인 발전을 거듭하여 2023년 YOLOv8, 2024년 YOLOv11를 발표하였다. 기존의 CNN 기반 모델이 객체를 탐지할 영역을 제안한 다음 CNN을 통해 해당 영역을 정확하게 찾는 두 단계 방식을 사용했다면, YOLO는 단일 네트워크를 통해 한 번의 연산으로 객체를 탐지하여 속도를 크게 향상시켰다. 이러한 특징 덕분에 실시간 모니터링이 필요한 다양한 분야에 널리 활용되었다. 그러나 초기 YOLO 모델은 기존 CNN에 비해 정확도가 다소 낮다는 한계가 있었고, 이를 극복하기 위해 지속적으로 성능이 개선되고 있다.

YOLOv8은 2023년에 발표된 YOLO 계열의 버전으로, 이전 버전들이 지닌 경량성과 효율성을 계승하면서 셀프 어텐션(self-attention)과 멀티 스케일링(multi-scaling)과 같은 최신 기법을 적용하여 탐지 속도와 정확도를 향상시켰다[18]. 특히, 경량화된 셀프 어텐션 모듈인 Convolutional Block Attention 모듈(CBAM)[19]을 도입하여 이미지에서 중요한 채널과 위치를 효과적으로 파악함으로써 CNN의 성능을 개선하였다. 또한, 다양한 크기의 객체를 더욱 정확하게 탐지할 수 있도록 고정된 앵커 박

스 대신 동적으로 변하는 박스(Dynamic Anchor-Free Detection)를 적용하여 모델이 다양한 객체 크기를 유연하게 인식할 수 있도록 하였다.

2.2 YOLOv8 특징

YOLOv8 시리즈는 나노(n), 스몰(s), 미디엄(m), 라지(l), 엑스라지(x)로 모델을 제공해, 유연한 성능 선택이 가능하다. 상황에 따라 정확도가 다소 낮더라도 경량 모델(n, s)을 택해 모바일·엣지 디바이스에 배포하거나, 최대한 높은 정확도를 요구하는 경우 대형 모델(l, x)을 선택할 수 있다.

본 연구는 정확하면서도 실시간으로 동작 가능한 객체 탐지를 실현하기 위해 안정성이 높고, 성능이 검증된 YOLOv8을 선택하였다. 또한, 낙상 이미지를 기반으로 낙상을 판단한 Krishnan et al.(2024)의 연구와 달리, 본 연구에서는 사람 객체의 움직임 패턴과 안전 가구와의 공간적 관계를 분석하여 낙상 상황을 판단하였다. 이러한 접근 방식을 통해 비접촉형 낙상 감지에 필요한 신속한 판단과 높은 검출 성능을 동시에 달성할 수 있을 것으로 기대한다.


3. 낙상 감지 시스템

3.1 시스템 개요

그림 1은 CCTV 영상 입력부터 안전 가구 감지, 사람 객체 검출 및 추적, 위험 상황 판단, 그리고 알림 전송까지의 전체 파이프라인으로 구성된 낙상 감지 시스템의 개요를 나타낸다. CCTV 영상에서 연속된 이미지가 입력되면, 안전 가구 감지(Safety Furniture Detection) 모듈과 사람 객체 추적(Person Tracking) 모듈을 통해 주요 객체들을 인식한다. 이후, 위험 상황 판단(Risk Assessment) 모듈에서는 사람 객체의 움직임 패턴과 안전 가구와의 공간적 관계를 종합적으로 분석하여 낙상 여부를 판단한다. 낙상이 의심되는 상황이 감지되면 즉시 알림을 전송하여 대응할 수 있도록 구성되어 있다. 각 단계별 세부적인 설명은 아래와 같다.

안전 가구 감지는 YOLOv8 시리즈 중 가장 높은 정확도를 제공하는 YOLOv8x(엑스라지) 모델을 사용하였다. 입력 영상의 첫 프레임에서 의자, 소파, 침대 등과 같이 낙상 충격을 완화할 수 있는 안전 가구를 탐지하며, 각 객체의 바운딩 박스(bounding box)와 중심점 정보를 추출

하여 저장한다. 이후 프레임에서는 저장된 정보를 재촬영함으로써 반복 검출로 인한 연산 비용을 줄였다. 이와 같은 정적 객체의 초기 탐지 및 정보 유지 전략은 시스템의 실시간성을 확보하는 데 중요한 역할을 한다.



(그림 1) 감지 모델의 순차적 흐름 다이어그램
(Figure 1) Flow Diagram of the Detection Model

3.2 사람 객체 검출 및 추적

사람 객체는 YOLOv8 모델을 통해 실시간으로 검출된다. 모델 배포 환경의 자원 상황(CPU/GPU 성능, 메모리 용량 등)이나 요구되는 응답 속도에 따라, YOLOv8 시리즈의 다양한 크기(nano, small, medium, large, xlarge) 중에서 적합한 모델을 선택하여 적용하거나 필요 시 전환할 수 있도록 구성하였다. 예를 들어, 연산 자원이 한정된 엣지(edge) 디바이스에서는 실시간 응답성을 확보하기 위해 나노(n)나 스몰(s)과 같은 경량 모델을 우선적으로 사용하며, 고정형 환경이나 GPU가 충분한 서버 환경에서는 보다 높은 정확도를 제공하는 미디엄(m), 라지(l), 엑스라지(x) 모델로 변경하여 사용하는 방식이다.

검출된 사람 객체는 모델의 트래킹 기능을 통해 고유 ID가 부여되며, 이후 프레임 간 바운딩 박스와 중심점을 지속적으로 갱신하여 각 객체의 이동 경로를 추적한다. 이를 바탕으로 사람의 상태를 ‘이동 중’ 또는 ‘정지 상태’로 판단한다. 본 연구에서는 이전 위치와 5픽셀 이상의 차이가 발생할 때 ‘이동 중’으로, 그렇지 않으면 ‘정지 상태’로 분류하였다.

3.3 위험 상황 판단 및 알림 전송

위험 상황은 사람 객체의 움직임 패턴과 안전 가구와의 공간적 관계를 종합적으로 분석하여 판단한다. 일정 시간 동안 움직임이 없고 안전 가구로부터 떨어진 경우를 낙상 가능성이 있는 상황으로 간주하였다.

안전 가구와 사람 객체 사이의 공간적 관계는 IoU (Intersection over Union) 지표를 통해 분석하였다. IoU는 모델이 예측한 바운딩 박스와 실제 객체 간 바운딩 박스가 얼마나 겹치는지를 나타내며, 이를 활용해 두 객체 간의 상대적인 거리를 간접적으로 추정할 수 있다. 본 연구에서는 IoU 기준값을 0.2로 고정하여 사용하였다. 정지 상태의 사람이 안전 가구와 떨어져 IoU 값이 일정 기준 이하로 감소하면 위험(Unsafe) 상황으로 판단하고, 반대로 안전 가구와 가까워 일정 수준 이상의 IoU 값을 유지할 때는 안전한(Safe) 상태로 간주하였다. 한편, 사람이 움직이는 경우는 일반적으로 위험성이 낮다고 판단하였고, 안전 가구 근처에서 움직일 경우 “Moving Near Safe Object”로 분류하였다.

위험 상황이 감지되면, SMS 알림 전송 기능을 통해 보호자나 관리자에게 신속하게 경고를 전달한다. 중복 알림 방지를 위해 알림 전송 이력을 관리하며, 동일한 객체에 대해 일정 시간 내 중복 경고가 발생하지 않도록 설계하였다. 본 연구에서는 클라우드 기반 커뮤니케이션 플랫폼인 Twilio API를 활용하여 SMS 알림 기능의 작동 여부를 시험하였다.

4. 실험 결과 및 분석

이번 장에서는 3장에서 제안된 YOLOv8 기반 낙상 감지 시스템이 정상적으로 동작하는지를 확인하기 위해, 먼저 YOLOv8 시리즈(nano, small, medium, large, xlarge) 모델들의 사람 탐지 성능을 평가하였다. YOLOv8 모델은 기본적으로 328,000장의 이미지로 구성된 COCO(Common Objects in Context)[20] 데이터셋을 활용해 사전 학습된 모델이며, 해당 데이터셋에는 의자, 소파, 침대와 같은 안전 가구와 사람 이미지가 포함되어 있다. 이에 따라, 본 연구에서는 제안된 시스템의 개념 검증(proof of concept)에 초점을 맞추어, 별도의 파인튜닝 없이 사전 훈련된 모델을 조합하여 사용하였다. 또한, 모든 실험은 Apple M1 노트북(8GB 메모리, 125GB 저장 공간)을 사용하여 수행되었다.

모델 예측 성능의 평가는 네 가지 요소로 구성된 혼동

행렬(confusion matrix)을 기반으로 이루어진다. 객체를 성공적으로 검출한 경우를 참 양성(true positive, TP)이라 하고, 객체가 없는 상황을 정확히 예측한 경우를 참 음성(true negative, TN)이라 한다. 반면, 객체가 없는데도 있는 것으로 잘못 탐지한 경우는 거짓 양성(false positive, FP), 실제 객체가 있음에도 탐지하지 못한 경우는 거짓 음성(false negative, FN)이라 한다. 이를 바탕으로 정밀도(Precision), mAP(mAP50, mAP50-95), 그리고 재현율(Recall)을 계산하여 모델 평가지표로 활용한다. 정밀도는 탐지한 객체 중 실제 객체를 올바르게 검출한 비율($P = \frac{TP}{TP+FP}$)을 나타낸다. 재현율은 실제 객체 중 모델이 성공적으로 예측한 비율($R = \frac{TP}{TP+FN}$)로 나타낸다. 평균 정밀도(mAP)는 개별 객체의 정밀도-재현율 곡선에서 얻은 정밀도의 평균 값($AP = \int_0^1 P dR$)으로 정의한다. N개 객체에 대한 평균 정밀도 값을 평균하면, $mAP = \frac{1}{N} \sum_{i=1}^N AP_i$ 가 되며, mAP가 클수록 모델의 탐지 성능이 뛰어나다. mAP50은 IoU가 0.5이상인 경우만 TP로 인정하는 방식이며, mAP50-95는 IoU기준을 0.5에서 0.95까지 0.05간격으로 변화시키며 평균을 내는 방식으로, mAP50에 비해 엄격한 평가 기준이다. F1-score($F1 = \frac{2PR}{P+R}$)는 정밀도와 재현율의 조화 평균으로, 두 지표 간의 균형을 종합적으로 평가하기 위해 사용한다. 전체 정확도($Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$)는 전체 모델 예측 중에서 실제 값과 일치한 비율로 정의된다.

4.1 사전 학습된 모델의 성능 평가

본 연구에서는 AI-Hub 시니어 이상행동 영상에서 추출한 연속된 181장의 이미지를 활용하여, 사전 학습된 YOLOv8 시리즈(nano, small, medium, large, xlarge) 모델들의 사람 검출 성능과 추론 속도를 비교·평가하였다. 이후로는 YOLOv8 나노 모델을 YOLOv8n, 스몰 모델을 YOLOv8s, 중간모델을 YOLOv8m, 대형 모델을 YOLOv8l, 초거대 모델을 YOLOv8x로 표기한다.


표 1은 YOLOv8 모델별 정밀도, 재현율, F1 score, 추론 속도(FPS, frames per second) 및 프레임당 처리 시간($ms/frame = \frac{1000}{FPS}$)을 나타낸다. 예상한 바와 같이 YOLOv8n 경량 모델이 초거대 모델 YOLOv8x에 비해 5배 정도 빠른 처리 속도를 보였다. 중간 크기의

(표 1) YOLOv8 모델별 정밀도, 재현율, F1 score, 추론 속도(FPS) 및 프레임당 처리 시간 (1000/FPS)

(Table 1) Precision, recall, F1 score, inference speed, processing time per of YOLOv8 Models

모델	정밀도	재현율	F1 Score	FPS	1000/FPS
v8n	0.80	0.50	0.61	5.98	167
v8s	0.84	0.65	0.73	4.76	210
v8m	0.95	0.65	0.77	2.46	407
v8l	0.92	0.74	0.82	1.53	654
v8x	0.98	0.94	0.96	1.17	845

YOLOv8m도 YOLOv8x에 비해 약 두 배 정도 빠른 것으로 나타났다. 이와 같은 결과는 모델의 크기에 따라 추론 성능에 큰 차이가 발생함을 보여주며, 시스템 적용 환경에 따라 적절한 모델 선택이 필요함을 의미한다.



(그림 2) YOLOv8 모델별 탐지 성능과 속도
(Figure 2) Detection performance and speed for YOLOv8 models

그림 2는 YOLOv8 모델별 탐지 성능과 속도 비교 결과를 보여준다. 전반적으로 모델 크기가 커질수록 검출 성능(mAP, Precision, Recall)이 향상되는 경향을 보였다. 예를 들어, 가장 큰 모델인 YOLOv8x는 mAP50-95와 재현율에서 0.96으로 가장 높은 값을 기록하였으며, 반대로 가장 작은 모델인 YOLOv8n은 0.5로 상대적으로 낮은 검출 성능을 보였다.

YOLOv8x는 높은 정확도를 보였으나, 평균 추론 시간이 길어 실시간 처리가 요구되는 환경에서는 부담이 될

수 있음을 확인하였다. 반면, 경량 모델인 YOLOv8n과 YOLOv8s는 각각 5.98 FPS, 4.76 FPS로 추론 속도가 빨랐지만, 정밀도는 각각 0.8, 0.836으로 대형 모델인 YOLOv8x, YOLOv8l, YOLOv8m 대비 낮았다.

특히 YOLOv8m은 mAP50-95가 59.7%, FPS가 2.46으로, 정확도와 추론 속도 간의 균형이 비교적 우수한 모델로 나타났다. 이러한 결과는 낙상 감지와 같이 실시간성과 정확도가 모두 요구되는 환경에서 YOLOv8m 모델이 실용적인 선택지가 될 수 있음을 시사한다. 요약하면, 검출 성능과 추론 속도 사이에는 분명한 트레이드오프(trade-off)가 존재하므로, 실제 시스템 설계 시에는 하드웨어 자원, 실시간성 요구사항, 엣지 디바이스 또는 서버 환경 등을 종합적으로 고려하여 모델을 선택해야 한다.

4.2 시나리오 실험

앞선 실험 결과, YOLOv8 시리즈 중 YOLOv8m 모델은 가장 큰 모델인 YOLOv8x 대비 추론 속도가 약 2배 빠르면서도(m모델 406.5ms/frame, x모델 845.3ms/frame), 경량 모델인 YOLOv8n에 비해 검출 정확도(mAP50-95 기준 m모델 59.7%, n모델 41.7%)가 약 18% 높아 정확도와 속도 측면에서 최적의 균형을 이루는 모델로 평가되었기에 사람 객체 검출 모델로 채택하였다.

(표 2) 다섯 가지 시나리오의 상황 및 기대 결과

(Table 2) Situations and expected outcomes for the five scenarios.

시나리오	상황	기대 결과
1	사람이 움직임	안전
2	사람이 안전 가구와 떨어져 바닥에 쓰러져 있음	위험
3	사람이 의자 위에 앉아 있음	안전
4	사람이 침대 위에서 지속적으로 움직임	안전
5	사람이 침대에서 낙상하여 침대와 떨어진 상태에서 미세하게 움직임	위험

이에 따라 실제 환경에서 제안 시스템의 성능을 평가하기 위해 시나리오 기반 실험을 진행했다. 본 연구에서는 시스템의 현실 적용성과 신뢰성을 확보하기 위해 총 다섯 가지 시나리오를 구성하여 실험을 진행했다. 각 시나리오의 상황 및 시스템의 기대 결과는 표 2에 요약하여 정리했다. 이 시나리오들은 사람이 안전 가구(의자,


침대 등) 주변을 이동하는 정상적인 상황(시나리오 1), 안전 가구와 멀리 떨어져 바닥에 쓰러져 있는 위험 상황(시나리오 2), 의자 위에 앉아 있는 안전한 정지 상황(시나리오 3), 침대 위에서 지속적으로 움직이는 안전한 활동 상황(시나리오 4), 그리고 침대에서 낙상하여 침대와 떨어진 상태에서 미세하게 움직이는 상황(시나리오 5)으로 구성하여 진행했다.



(그림 3) 시나리오 1: 사람이 안전 가구 주변을 이동하는 정상적인 상황

(Figure 3) Scenario 1: A person moving near safety furniture in a safe situation

시나리오 1은 사람이 이동하는 상황을 12초 영상으로 기록하였다. YOLOv8m은 사람 객체를 정확하게 검출하고, 프레임 간 중심점 이동 패턴을 분석하여 ‘이동 중’ 상태를 정확히 판단했다. 특히, 사람과 안전 가구의 거리에 따라 ‘Moving’과 ‘Moving Near Safe Object’ 두 상태를 성공적으로 구분함을 확인했다. 각 프레임에는 바운딩 박스, 고유 ID, 이동 궤적이 시각적으로 오버레이되어 실제 이동 여부를 명확히 확인할 수 있었으며, 그림 3의 오른쪽에서 보듯이 YOLO 모델이 사람 객체(노란색 박스)를 안정적으로 추적하고 있는 모습을 확인할 수 있다. 모델 성능 평가는 라벨링된 29장의 이미지를 대상으로 수행하였으며, ‘Moving’과 ‘Moving Near Safe Object’ 두 클래스에 대해서 정밀도, 재현율, F1-score를 측정하였다. ‘Moving’ 상태에서는 정밀도 0.86, 재현율 0.90, F1-score 0.88을 기록했고, ‘Moving Near Safe Object’ 상태에서는 정밀도 0.75, 재현율 0.67, F1-score 0.71을 보였다. 전체 정확도는 29장 중 24장을 정확하게 예측하여 0.83을 나타냈다.




(그림 4) 시나리오 2: 사람이 바닥에 누워 있고 안전 가구와 떨어진 위험 상황

(Figure 4) Scenario 2: A person lying on the floor away from safety furniture in a hazardous situation

시나리오 2는 사람이 바닥에 누워 거의 움직이지 않으며, 안전 가구와 떨어져 있는 전형적인 낙상 사례를 다룬다. 해당 상황은 25초 영상으로 기록하였다. 시스템은 중심점 이동 거리와 안전 가구와의 거리 정보를 종합적으로 분석하여 사람 객체의 정지 상태를 판단했다. 그림 4의 왼쪽에서는 사람이 움직임 없이 안전 가구에서 떨어진 위치에 누워 있는 장면이 붉은색 바운딩 박스로 시각화되어 낙상 상태(Unsafe)로 탐지된 모습을 보여준다. 모델 성능 평가는 라벨링된 65장의 이미지를 대상으로 수행하였으며, ‘Moving’과 ‘Unsafe’ 두 클래스에 대해서 정밀도, 재현율, F1-score를 측정하였다. ‘Moving’ 상태에서는 정밀도 0.8, 재현율 1.00, F1-score 0.89를 기록했고, ‘Unsafe’ 상태에서는 정밀도 1.00, 재현율 0.96, F1-score 0.98을 보였다. 전체 정확도는 64장 중 62장을 정확하게 예측하여 0.97을 나타냈다. 이러한 결과는 본 연구의 핵심 목표인 낙상과 같은 위험 상황에 대한 우수한 탐지 성능을 보여준다.

시나리오 3은 사람이 의자에 앉아있는 6초 영상으로, 24장의 이미지를 평가에 활용하였다. 시스템은 사람과 안전 가구 사이의 IoU를 기준으로 해당 상태를 ‘안전한 상태’(Safe)로 판단하는지를 확인했다. 그림 5의 중앙에서는 사람이 움직임 없이 의자에 앉아 있는 장면이 녹색 바운딩 박스로 시각화되어 있으며, 움직임이 없는 정지 상태임에도 불구하고 안전 가구와의 겹침을 기준으로 이를 안전한 상황으로 분류함을 확인할 수 있었다.


초기 프레임에서 안전 가구(의자)를 탐지하고 정보를 저장했으며, 이후 사람 객체와의 공간적 관계를 지속적으로 추적했다. 사람 객체는 중심점 이동이 거의 없어 정지 상태로 판단되었고, 안전 가구와의 IoU가 충분히 높아 ‘Safe’ 클래스로 정확히 분류되었다.



(그림 5) 시나리오 3: 사람이 의자에 앉아 있는 정지 상태의 안전 상황

(Figure 5) Scenario 3: A person sitting still on a chair in a safe situation


‘Moving’, ‘Moving Near Safe Object’, ‘Safe’ 세 클래스에 대해 정밀도, 재현율, F1-score를 측정하였다. ‘Moving’ 상태에서는 정밀도 1.0, 재현율 1.0, F1-score 1.0을 기록했고, ‘Moving Near Safe Object’ 상태에서는 정밀도 1.0, 재현율 0.88, F1-score 0.93을 보였다. ‘Safe’ 상태에서는 정밀도 0.91, 재현율 1.0, F1-score 0.95를 나타냈으며, 전체 정확도는 24장 중 23장을 정확하게 예측하여 0.96을 달성하였다. 이를 통해 안전 가구 근처에서 정지 상태의 사람을 안전 상태로 분류하는 로직이 작동함을 확인할 수 있다.



(그림 6) 시나리오 4: 사람이 침대 위에서 활동하는 안전 상황
(Figure 6) Scenario 4: A person active on the bed in a safe situation

시나리오 4는 사람이 침대 위에서 지속적으로 움직이는 상황으로 15초 영상으로 기록하였다. 시스템은 초기

에 안전 가구인 침대를 탐지하고 중심점 정보를 저장했으며, 이후 실시간으로 검출한 사람 객체와의 IoU를 측정하였다. 평가는 76장의 이미지를 활용해 이루어졌으며, ‘Moving’, ‘Moving Near Safe Object’, ‘Safe’ 세 클래스에 대해 정밀도, 재현율, F1-score를 측정하였다. ‘Moving’ 상태에서는 정밀도 0.56, 재현율 0.63, F1-score 0.59를 기록했고, ‘Moving Near Safe Object’ 상태에서는 정밀도 0.80, 재현율 0.92, F1-score 0.85을 보였다. ‘Safe’ 상태에서는 정밀도 0.5, 재현율 0.24, F1-score 0.32를 나타냈으며, 전체 정확도는 76장 중 56장을 정확하게 예측하여 0.74을 달성하였다. 시나리오 3과는 달리, 본 시나리오에서는 사람이 지속적으로 움직이기 때문에, 침대 위에서 정지 상태를 나타내는 ‘Safe’ 클래스를 판단하는 성능이 낮게 나타났다. 이는 본 연구에서 사용한 바운딩 박스 중심점 기반 움직임 판별 방식이 정밀한 판단을 요구하는 상황에는 한계가 있다는 것을 시사한다. 따라서 향후에는 LSTM과 같은 시계열 예측 알고리즘을 적용하여 연속적인 이미지를 처리할 수 있는 방안을 검토할 필요가 있다.



(그림 7) 시나리오 5: 낙상 후 침대와 떨어진 상태에서 미세하게 움직이는 위험 상황(Unsafe)

(Figure 7) Scenario 5: A person has fallen from the bed, is positioned away from it, and shows only slight movements.

시나리오 5는 침대에서 낙상하여 침대와 떨어진 상태에서 미세하게 움직이는 위험 상황을 다룬다. 31초 영상을 기록하였으며, 134장 이미지를 평가에 사용하였다. 초기 프레임에서는 사람이 침대 근처에 있어서

IoU가 높게 유지되며 ‘안전적 상태’로 감지되었지만, 침대에서 멀어짐에 따라 ‘위험 상태’로 분류되었다. 몸을 크게 움직이는 순간에는 ‘이동 중’으로 판단하였지만, 미세한 움직임은 ‘정지’로 분류되어 안전 가구에서 떨어져 정지해 있는 위험 상태로 분류되었다. ‘Moving’, ‘Moving Near Safe Object’, ‘Safe’, ‘Unsafe’ 네 클래스에 대해 정밀도, 재현율, F1-score를 측정하였다. ‘Moving’ 상태에서는 정밀도 0.38, 재현율 0.7, F1-score 0.50를 기록했고, ‘Moving Near Safe Object’ 상태에서는 정밀도 0.73, 재현율 0.92, F1-score 0.81을 보였다. ‘Safe’ 상태에서는 정밀도 0.88, 재현율 0.70, F1-score 0.78를 나타냈으며, ‘Unsafe’ 상태에서는 정밀도 0.93, 재현율 0.76, F1-score 0.83를 나타냈다. 전체 정확도는 134장 중 102장을 정확하게 예측하여 0.76을 달성하였다. 시나리오 4에서 본 것처럼, ‘Moving’ 상태에 대한 예측 성능이 낮았는데, 본 연구에서 사용한 바운딩 박스 중심점 기반 움직임 판별 방식이 미세한 움직임을 측정하는데 정교하지 않다는 것을 의미한다.

표 3은 다섯 가지 시나리오별 사용된 영상의 길이, 평가에 사용된 이미지 수, 그리고 시스템의 전체 정확도를 요약한 것이다. 시나리오 1, 2, 3처럼 사람이 움직이거나 정지해 있는 경우에는 높은 정확성을 보였으나, 시나리오 4, 5처럼 움직임과 정지가 반복하는 패턴에서는 정확도가 낮아지는 경향을 확인했다. 이는 바운딩 박스 중심점 기반 움직임 판별 방식의 특성상 적절한 임계값을 설정하기 위한 민감도 실험이 필요함을 시사한다. 또한 정확도 향상을 위해서 객체의 시간적 변화를 반영할 수 있는 방법을 도입해야 한다.

(표 3) 다섯 가지 시나리오에 대한 영상 길이, 평가에 사용된 이미지 수와 모델의 전체 정확도

(Table 3) Video length, number of images used for evaluation, and overall model accuracy for the five scenarios.

시나리오	영상길이 [초]	이미지수 [장]	Overall Accuracy
1	12	29	0.8276
2	25	64	0.9688
3	6	24	0.9583
4	18	76	0.7368
5	31	134	0.7612

5. 결 론

본 연구에서는 YOLOv8 기반의 객체 검출 및 객체 추적 기술을 활용하여 낙상 감지 시스템을 제안하였다. 제안 시스템은 CCTV 영상에서 사람 객체와 안전 가구(의자, 소파, 침대 등)를 검출 및 추적하고, 이들 간의 공간적 관계와 움직임 패턴을 분석하여 낙상 가능성이 있는 위험 상황을 판단한다. 또한 낙상으로 추정되는 상황이 감지될 경우, SMS 알림을 전송하는 통합 파이프라인 구조를 통해 신속한 대응이 가능하도록 설계하였다. CCTV 기반 접근 방식은 라이더나 열화상 카메라에 비해 설치 비용이 저렴하고, 이미 설치된 환경이 많아 활용성이 높다. 또한 웨어러블 장비와 달리 비접촉 방식으로 작동하며, 충전이나 착용에 대한 부담이 없어 실사용자에게 적합하다.

YOLOv8 시리즈(n, s, m, l, x)를 비교 실험한 결과, 사람 객체 검출에는 탐지 정확도와 추론 속도 간 균형이 우수한 YOLOv8m 모델이 적합한 것으로 나타났으며, 정적인 안전 가구 검출에는 정확도가 높은 YOLOv8x 모델을 적용하여 인식 신뢰도를 향상했다. 제안 시스템이 실제 환경에서 정상적으로 작동하는지 확인하기 위해 다섯 가지 시나리오를 구성해 실험을 진행했다. 실험 결과, 전반적으로 시스템은 위험 상황 탐지에서 높은 정확도를 보였다. 특히, 안전 가구와 사람 객체 사이의 공간적 관계 분석이 낙상 위험 탐지에 효과적으로 활용될 수 있음을 확인했다. 이러한 결과는 낙상 이미지 기반 탐지 모델과 결합할 경우, 낙상 탐지 정확도를 더욱 향상시킬 가능성을 보여주었다는 점에서 의의가 있다. 하지만, 움직임과 정지가 반복되는 상황에서는 이를 보다 정밀하게 구분하기 위해 객체의 시간적 변화를 반영할 수 있는 방법을 도입할 필요가 있다.

향후 연구에서는 낙상 이미지를 위험 상태로 인식할 수 있도록 사전 훈련된 모델을 파인튜닝하고, 이를 제안된 시스템과 결합하여 낙상 탐지 성능을 높일 계획이다. 또한, 사람 객체의 연속된 움직임 패턴을 보다 정밀하게 분석하기 위해, LSTM과 같은 딥러닝 기반 시계열 모델과 결합하는 연구도 수행할 예정이다. 뿐만 아니라, 요양원과 같은 현장에서 영상 자료를 확보해 다른 딥러닝 모델과의 검증에 활용할 계획이다.

참고문헌(Reference)

- [1] World Health Organization, WHO, Number of People Over 60 Years Set to Double by 2025; Major Societal Changes Required, 2015.
<https://www.who.int/news/item/30-09-2015-who-number-of-people-over-60-years-set-to-double-by-2050-major-societal-changes-required>
- [2] Statistics Korea, 2024 Statistics on the Aged, 2024.
https://kostat.go.kr/board.es?mid=a20111030000&bid=11759&act=view&list_no=433631
- [3] National Academies of Sciences, Medicine, Division of behavioral, Social Sciences, Medicine Division, Board on Behavioral, Sensory Sciences et al., "Social isolation and loneliness in older adults: Opportunities for the health care system," National Academies Press, 2020.
<https://doi.org/10.17226/25663>
- [4] Ren, Lingmei, and Yanjun Peng, "Research of fall detection and fall prevention technologies: A systematic review," IEEE Access, Vol. 7, pp.77702-77722, 2019.
<https://doi.org/10.1109/ACCESS.2019.2922708>
- [5] Pierleoni, P., A. Belli, L. Palma, M. Pellegrini, L. Pernini, and S. Valenti, "A high reliability wearable device for elderly fall detection," IEEE Sensors Journal, Vol. 15, No. 8, pp. 4544-4553, 2015.
<https://doi.org/10.1109/JSEN.2015.2423562>
- [6] Zigel, Yaniv, Dima Litvak, and Israel Gannot, "A method for automatic fall detection of elderly people using floor vibrations and sound-Proof of concept on human mimicking doll falls," IEEE Transactions on Biomedical Engineering, Vol. 56, No. 12, pp. 2858-2867, 2009.
<https://doi.org/10.1109/TBME.2009.2030171>
- [7] Bouazizi, Mondher, Chen Ye, and Tomoaki Ohtsuki, "2-D LIDAR-based approach for activity identification and fall detection," IEEE Internet of Things Journal, Vol. 9, No. 13, pp. 10872-10890, 2022.
<https://doi.org/10.1109/JIOT.2021.3127186>
- [8] Fan, Xiuyi, Huiguo Zhang, Cyril Leung, and Zhiqi Shen, "Robust unobtrusive fall detection using infrared array sensors," in Proc. of the 2017 IEEE International Conference on Multisensor Fusion and

- Integration for Intelligent System (MFI), pp. 194-199, 2017.
<https://doi.org/10.1109/MFI.2017.8170428>
- [9] Benkaci, Ama, Layth Sliman, and Hachemi Nabil Dellys, "Vision-based human fall detection systems: A review," *Procedia Computer Science*, Vol. 241, pp. 203-211, 2024.
<https://doi.org/10.1016/j.procs.2024.08.028>
- [10] Redmon, J., S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, real-time object detection," in *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 779-788, 2016. <https://doi.org/10.1109/CVPR.2016.91>
- [11] Yu, Miao, Liyun Gong, and Stefanos Kollias, "Computer vision based fall detection by a convolutional neural network," in *Proc. of the 19th ACM International Conference on Multimodal Interaction*, pp. 416-420, 2017.
<https://doi.org/10.1145/3136755.3136802>
- [12] Núñez-Marcos, Adrián, and Ignacio Arganda-Carreras, "Transformer-based fall detection in videos," *Engineering Applications of Artificial Intelligence*, Vol. 132, 107937, 2024. <https://doi.org/10.1016/j.engappai.2024.107937>
- [13] Núñez-Marcos, Adrián, Gorka Azkune, and Ignacio Arganda-Carreras, "Vision-based fall detection with convolutional neural network," *Wireless Communications and Mobile Computing*, Vol. 1, 9474806, 2017.
<https://doi.org/10.1155/2017/9474806>
- [14] Tian, Z., L. Zhang, G. Wang, and X. Wang, "An RGB camera-based fall detection algorithm in complex home environments," *Interdisciplinary Nursing Research, Wireless Communications and Mobile Computing*, Vol. 1, No. 1, pp. 14-26, 2022.
<https://doi.org/10.1097/NR9.0000000000000007>
- [15] Lu, N., Y. Wu, L. Feng, and J. Song, "Deep learning for fall detection: Three-dimensional CNN combined with LSTM on video kinematic data," *IEEE Journal of Biomedical and Health Informatics*, Vol. 23, No. 1, pp. 314-323, 2019.
<https://doi.org/10.1109/JBHI.2018.2808281>
- [16] Gomes, M. E. N., D. Macêdo, C. Zanchettin, P. S. G. de-Mattos-Neto, and A. Oliveira, "Multi-human fall detection and localization in videos," *Computer Vision and Image Understanding*, Vol. 220, 103442, 2022.
<https://doi.org/10.1016/j.cviu.2022.103442>
- [17] Agrawal, Madhuri, and Shikha Agrawal, "Enhanced deep learning for detecting suspicious fall event in video data," *Intelligent Automation and Soft Computing*, Vol. 36, No. 3, pp. 2653-2667, 2023.
<https://doi.org/10.32604/iasc.2023.033493>
- [18] Krishnan, T. V., B. K. Abhilash, and S. Govind, "A robust fall detection system for elderly persons using YOLO," in *Proc. of the 5th International Conference on Innovative Trends in Information Technology (ICITIIT)*, pp. 1-5, 2024. <https://doi.org/10.1109/ICITIIT61487.2024.10580626>
- [19] Woo, S., J. Park, J. Y. Lee, and I. S. Kweon, "CBAM: Convolutional block attention module," in *Proc. of the European Conference on Computer Vision (ECCV)*, pp. 3-19, 2018.
https://doi.org/10.1007/978-3-030-01234-2_1
- [20] T.-Y. Lin, M. Maire, S. J. Belongie, L. D. Bourdev, R. B. Girshick, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, "Microsoft COCO: Common objects in context," in *Proc. of the Computer Vision-ECCV: 13th European Conference*, pp. 740-755, 2014.
https://doi.org/10.1007/978-3-319-10602-1_48

● 저 자 소 개 ●



김 동 욱(Doung Uk Kim)

2025년 고려대학교 세종캠퍼스 컴퓨터소프트웨어학과(공학사)

관심분야 : 영상처리, 컴퓨터비전, 딥러닝, 클라우드, 데이터베이스 시스템 및 성능 최적화

E-mail : dong5478@korea.ac.kr



강 신 후(Shinhoo Kang)

2007년 한동대학교 전산전자공학부(공학사)

2007년 한동대학교 대학원 공간설계학과(공학석사)

2019년 The University of Texas at Austin, Dept. of Aerospace Engineering and Engineering Mechanics(공학박사)

2024년~현재 고려대학교 세종캠퍼스 컴퓨터소프트웨어학과 조교수

관심분야 : 과학계산, 영상처리, 수치모델링, 고성능머신러닝

E-mail : shinkang@korea.ac.kr